

项目报告

UnifoLM-WMA-0 具身世界模型优化

作者: 陈侯超
代码仓库: unifolm-world-model-action
报告日期: 2026年7月13日

目录

1 项目简介 2

1.1 项目目标与评测约束 2

1.2 代码结构与模型流程 2

1.3 运行环境 2

2 最终运行结果 3

2.1 测量方法 3

2.2 总体与逐场景结果 3

2.3 比较口径与结果边界 4

3 采用的优化及其在 G1 case 1 上的效果 4

3.1 性能分析依据与总体效果 4

3.2 G1 case 1 完整优化链 4

3.3 各项保留优化 5

4 放弃的优化及放弃原因 7

1 项目简介

1.1 项目目标与评测约束

本项目对应 ASC26 预赛第3题，目标是在保证生成视频质量的前提下，加速 UnifoLM-WMA-0 世界模型的推理。测试集包含5个机器人场景，每个场景4个样例，共20个样例。官方以每个样例脚本中 Bash time 输出的 real 时间作为性能指标；每个生成视频均须满足 $PSNR \geq 25$ dB，否则该场景记零分（官方通知 PDF 第5–10页）。

与实现直接相关的约束包括：权重精度不得低于16位；除 CUDA_VISIBLE_DEVICES 外不修改样例脚本；推理 YAML 仅允许调整 data_dir；不得修改输入；输出仍须保持赛事规定的 MP4 和目录结构。当前 YAML 的 data_dir 指向 examples/world_model_interaction_prompts。该路径提供与测试视频匹配的动作和状态归一化统计量，是修复 G1 基线质量的必要条件，不作为性能优化计入。

证据： /home/cyc/ASC26_Preliminary_Round_Notification.pdf

证据： configs/inference/world_model_interaction.yaml

1.2 代码结构与模型流程

核心模型代码位于 src/unifolm_wma/，其中 models/ 实现扩散模型与采样流程，modules/ 包含网络、注意力和 VAE 等组件，data/ 与 utils/ 提供数据和公共功能。推理入口位于 scripts/evaluation/world_model_interaction.py，配置位于 configs/inference/；5个场景的4组样例脚本分别位于仓库根目录对应的 unitree_*/case1--case4 目录。

当前配置实例化 LatentVisualDiffusion。图像先由 VAE 编码为潜表示，OpenCLIP 提供条件信息，扩散视频主干预测潜空间视频；两个独立的一维 U-Net head 分别预测动作和状态，最终由 VAE 解码模拟视频。每轮交互包含两个阶段：

- 1. **决策阶段**：根据指令和当前观测预测候选动作；
- 2. **模拟阶段**：以候选动作为条件预测后续视频和状态，并把执行帧送入下一轮。

每个样例使用50步动作 DDIM 和50步视频 DDIM，生成窗口为16帧，batch size 为1，输出分辨率为512×320。不同场景执行7、8、11或12轮外层交互，因此热点主要来自大量重复、形状固定的去噪计算，以及每个样例独立进程产生的启动和输出开销。

证据： README.md

证据： scripts/evaluation/world_model_interaction.py

证据： configs/inference/world_model_interaction.yaml

1.3 运行环境

项目	实测配置
主机与 CPU	sc4；2× Intel Xeon Platinum 8558P，共96个在线 CPU
内存	2.0 TiB
GPU	4× NVIDIA A100 80GB PCIe（SM80）；最终测试每次独占一块 GPU
软件	Python 3.10.20；PyTorch 2.3.1+cu121；CUDA runtime 12.1
检查点	/opt/unifolm_wma_dual.ckpt
网络策略	HF_HUB_OFFLINE=1；最终运行未发生网络访问

证据： profiles/full_case_validation/20260713_final_exclusive_performance/environment.json

2 最终运行结果

2.1 测量方法

最终评价严格串行运行20个仓库样例脚本，每个脚本启动独立 Python 进程。每个样例 开始前确认全部四块 GPU 空闲，运行时每两秒采样一次进程和 GPU 状态；没有观察到 并发计算进程。正式用时采用脚本内部的 Bash `real`，生成视频使用 `ffprobe` 和赛事 PSNR 脚本验证。日志同时检查 `traceback`、OOM、网络访问、进程被终止和意外 AOT 重编译。

`WMA_TORCH_COMPILE_VALIDATE=1` 在最终运行中保持启用，因此首次动作/状态图相对 `eager/exported` 路径的语义验证也计入每个样例时间。20个视频与较早的四 GPU 完整 运行按 SHA-256 比较后全部一致。

证据： `profiles/full_case_validation/20260713_final_exclusive_performance/final_audit.md`

证据： `profiles/full_case_validation/20260713_final_exclusive_performance/run_all.log`

2.2 总体与逐场景结果

20个样例全部成功并通过 PSNR 阈值。内部 `real` 总和为 **3909.336 s**，单样例平均为 **195.467 s**。

表 1: 最终 GPU 独占运行结果。时间取自 Bash `real`；PSNR 由赛事提供的脚本计算。完整场景标识符保留在源汇总 JSON 中。

场景	样例	GPU	用时 (s)	PSNR (dB)
G1 收纳相机	1	0	220.875	29.9133
G1 收纳相机	2	1	203.338	36.2159
G1 收纳相机	3	2	196.681	30.8426
G1 收纳相机	4	3	219.312	31.7124
Z1 双臂收拾铅笔	1	0	163.353	44.0370
Z1 双臂收拾铅笔	2	0	163.878	45.9187
Z1 双臂收拾铅笔	3	0	164.401	38.1130
Z1 双臂收拾铅笔	4	0	163.525	45.3399
Z1 双臂叠箱	1	0	144.551	40.4148
Z1 双臂叠箱	2	0	145.399	39.3027
Z1 双臂叠箱	3	0	145.676	38.7334
Z1 双臂叠箱	4	0	144.248	39.3359
Z1 双臂叠箱 V2	1	0	219.623	25.0862
Z1 双臂叠箱 V2	2	0	219.101	26.3119
Z1 双臂叠箱 V2	3	0	219.432	29.4278
Z1 双臂叠箱 V2	4	0	219.794	25.8804
Z1 叠箱	1	0	238.866	41.3632
Z1 叠箱	2	0	239.098	35.7335
Z1 叠箱	3	0	239.784	45.4037
Z1 叠箱	4	0	238.401	47.6774

最低 PSNR 为 Z1 双臂叠箱 V2 case 1 的 **25.0862 dB**，仅比阈值高 0.0862 dB；最高值为 Z1 叠箱 case 4 的 47.6774 dB。最终共输出 3136 个解码帧，所有视频均为 H.264、512×320、8 fps。

2.3 比较口径与结果边界

目前只保留5个原始未优化计时：G1 四个样例 平均1018.452 s，最终平均210.052 s，降低79.38%；Z1 双臂叠箱 case 1 由 684.410 s 降至144.551 s，降低78.88%。其中 G1 case 1 的原始值1008.587 s 来自数据路径修正后的运行；较早的 G1 case 2-4 视频产生于归一化问题修正之前，因此只保留其时间，不将其 PSNR 作为受控质量对照。其余15个样例没有原始基线，本文不推算缺失数据。

最终独占表中每个样例只运行一次，因此没有量化运行间方差。AOT 产物绑定于当前的 PyTorch 2.3.1+cu121、CUDA runtime 12.1、FP16、计算图 ABI 和 SM80；更换软件栈或 GPU 后必须重新构建并复测全部 PSNR。V2 case 1 的质量余量很小，是后续复测的首要风险样例。

证据：profiles/full_case_validation/20260713_final_exclusive_performance/summary.json

证据：baselines

3 采用的优化及其在 G1 case 1 上的效果

3.1 性能分析依据与总体效果

分阶段计时与 NVTX 区间覆盖启动、DDIM、VAE、动作/模拟阶段和输出；Nsight Systems 用于观察系统级时间线，Nsight Compute 用于检查 kernel。保留的一份编译后稳态报告显示：FP16 GEMM 占捕获 GPU kernel 时间的13.6%，NCHW 到 NHWC 布局转换占 11.9%，一个卷积组占 7.7%，Flash Attention 组占3.0%，同时存在大量 Triton 逐元素 kernel。CUDA API 汇总的两个启动入口合计超过88万次调用。由此优先处理重复 编码、无效 head、图恢复、进程启动和输出，并使用编译器融合固定形状热点。

修正数据后的原始 G1 case 1 为1008.587 s / 35.6154 dB，最终独占运行结果为 220.875 s / 29.9133 dB；整体用时降低 **78.10%**，吞吐率达到 **4.57×**。这是全部保留优化共同作用的结果，不能用于推断任一单项的贡献。

证据：profiles/nsys_compiled_steady_g1_case1/fp16_inductor_default_startup_niter2/cuda_gpu_kern_sum.txt

证据：profiles/nsys_compiled_steady_g1_case1/fp16_inductor_default_startup_niter2/cuda_api_sum.txt

3.2 G1 case 1 完整优化链

配置	用时 (s)	相对上一项的降幅	PSNR (dB)
修正数据后的原始基线	1008.587	–	35.6154
+ FP16 autocast	503.650	50.06%	32.4669
+ FP16 全精度归约	503.380	0.05%	32.8414
+ 固定形状编译与 SDPA	358.140	28.85%	31.0206
+ 异步输出	336.410	6.07%	31.0206
+ 启动路径缩减	312.530	7.10%	31.0206
+ 观测缓存、活跃 head 与单图	296.310	5.19%	33.0184
+ AOT 仅加载	261.898	11.61%	32.0566
+ meta 初始化	237.192	9.43%	29.9133
+ 仅最终输出	226.761	4.40%	29.9133
+ 动作阶段跳过解码	220.254	2.87%	29.9133
最终独占复测	220.875	–	29.9133

表 2: G1 case 1 完整优化链。每个百分比只与上一行比较。

从修正数据后的原始基线到动作阶段跳过解码，用时合计降低78.16%；最终独占复测的 总体降幅为 78.10%，其相对上一行慢0.28%属于运行波动，不计作优化退化。各里程碑来自 不同开发阶段，且固定形状编译/SDPA、观测缓存/活跃 head/单图均为组合改动；PSNR 还会 受到数值路径和 meta

初始化随机数流变化的影响。因此，相邻百分比用于描述端到端阶段 结果，不能作为各项贡献可相加的独立因果归因。

3.3 各项保留优化

1. FP16 混合精度。 动作和模拟阶段在 CUDA FP16 autocast 中运行，存储权重不低于16位。在相同官方输入上，修正后的原始路径由1008.587 s / 35.6154 dB 变为503.65 s / 32.4669 dB，用时降低 50.06%，吞吐率约为2.00×。该结果是一个粗粒度前后对照，不能与后续局部降幅 相加。`WMA_FP16_FULL_REDUCTION=1` 进一步禁止 FP16 矩阵归约使用低精度累加，结果由503.65 s / 32.4669 dB 变为503.38 s / 32.8414 dB。其0.054%时间变化不构成 加速结论，保留该设置是因为 PSNR 提高。

证据: `baselines/2026-07-12_g1_pack_camera_case1_corrected_official_data`

证据: `baselines/2026-07-12_g1_pack_camera_case1_fp16`

证据: `profiles/fp16_precision_ablation/RESULTS.md`

2. 固定形状完整图编译、SDPA 与异步输出。 去噪器通过纯张量、固定形状适配器交给 `torch.compile/Inductor` 完整图编译，动作注意力使用 SDPA。两项共同把 G1 case 1 从 503.38 s / 32.8414 dB 降至 358.14 s / 31.0206 dB，用时降低28.85%；现有日志同时启用两项，不能继续拆分归因。随后把视频编码移出关键同步路径，完整运行降至336.41 s / 31.0206 dB，又降低6.07%。

证据: `profiles/torch_compile_g1_case1/stage3c_full_case1_dtype_fixed`

证据: `profiles/async_output_g1_case1/stage5b_full_case1`

证据: `src/unifolm_wma/modules/attention.py`

3. 观测缓存、活跃 head 剪枝和单一通用图。 一次 DDIM 调用的50个步骤使用相同观测，因此每次调用只编码一次动作/状态观测；外层观测变化后重新计算。缓存单项局部实验由312.53 s / 31.0206 dB 降至 286.78 s / 27.5340 dB，降低8.24%，但它不是最终采用的独立配置。决策阶段只运行动作 head，模拟阶段只运行状态 head，并跳过不活跃 head 的 scheduler。为避免恢复两份共享视频主干，单一导出模板把动作或状态 head 权重作为输入选择。缓存与双图组合为305.05 s / 30.1135 dB，最终采用的缓存与单一通用图组合为 296.31 s / 33.0184 dB；相对双图快2.87%，相对312.53 s局部起点快5.19%。这些并列实验的数值路径不同，不能与表 2 的增量相加。

证据: `profiles/generic_phase_optimization/report.md`

证据: `profiles/full_case_validation/20260713_final_exclusive_performance/report.md`

证据: `src/unifolm_wma/models/samplers/ddim.py`

4. 启动路径缩减。 统一检查点已经包含 OpenCLIP 最终权重，因此跳过两次冗余预训练权重加载；同时跳过推理不使用的 EMA 副本，使用 `mmap=True` 读取只含张量的检查点，并通过 `load_state_dict(strict=True, assign=True)` 严格赋值。该组合把 G1 模型启动冒烟路径从62.80 s 降至39.88 s，完整运行从336.41 s 降至312.53 s，降低7.10%。

证据: `profiles/startup_optimization`

5. AOTInductor 仅加载。 固定图在评测前预编译为共享库，样例进程只加载产物。一次构建耗时 2647.289 s，生成2.70 MiB 软件包；最终20个进程均命中该包，最大共享库加载时间为1.034 ms，没有发生重建。G1 case 1 从296.310 s 降至261.898 s，降低11.61%。构建成本在 评测前摊销，并未消失；产物加载前还会校验元数据和 sidecar 哈希。

证据: `profiles/aot_meta_final_optimization/stage1_aot_build/run.log`

证据: `profiles/aot_meta_final_optimization/stage1_aot_full/run.log`

证据: `profiles/full_case_validation/20260713_final_exclusive_performance/final_audit.md`

6. Meta 初始化。 模型架构先在 meta 设备构造，再从检查点实体化并恢复7个必需缓冲区。架构构造时间从 25.654 s 降至1.254 s；在 AOT 仅加载基础上，G1 总时间由261.898 s 降至237.192 s，降低9.43%。常规构造会消耗 CPU 随机数而 meta 构造不会，后续 VAE 后验采样因而 改变潜变量序列；G1 PSNR 从32.0566变为29.9133 dB。严格键加载、缓冲区恢复和无残留 meta 张量均已验证，但本文不声称两种初始化数值等价。

证据: `profiles/aot_meta_final_optimization/stage2_aot_meta_full/run.log`

7. 仅最终输出与动作阶段跳过 VAE 解码。 赛事只需要最终拼接视频，因此预分配 GPU 缓冲区保存实际执行帧，最后一次性传输和编码，并省略逐轮 TensorBoard/MP4 输出。G1 case 1 由 237.192 s 降至 226.761 s，降低 4.40%。动作阶段的像素视频不会被后续计算使用，跳过该阶段 VAE decode 后又降至 220.254 s，降低 2.87%。优化前后最终 MP4 的 SHA-256 完全一致，PSNR 均为 29.9133 dB。

证据: `profiles/aot_meta_final_optimization/stage3_aot_meta_final_full`

证据: `profiles/action_skip_decode/g1_case1_full`

4 放弃的优化及放弃原因

下表只比较每项实验自身的对照。各数值来自不同开发阶段，不能跨行相加，也不能与 表 2 合并计算总加速比。

方案	关键实测结果	放弃原因
40/40 DDIM 步数	G1 case 1: 18.0746 dB	PSNR 远低于25 dB；粗扫并发计时不作为可靠速度对比，保留50/50步。
批量 VAE	Z1 双臂叠箱 case 1: 692.795 s, 43.7248 dB; 原始单次对照684.410 s	该次运行未优于对照；日志含网络重试且无重复测量，未获得可确认收益。
TF32	Z1 双臂叠箱 case 1: 418.839 s, 38.9275 dB	明显慢于 FP16 的362.218 s。
BF16	同一样例: 361.311 s, 26.9565 dB	与 FP16 延迟相当，但 PSNR 明显低于 FP16 的42.3686 dB。
动作/状态 scheduler FP32	G1 case 1: 503.56 s, 27.4513 dB; FP16 对照 503.65 s, 32.4669 dB	时间几乎不变，PSNR 降低。
显式视频 DDIM FP32	G1 case 1: 502.49 s, 32.4669 dB	输出逐字节相同，无明确时间收益。
交叉注意力 K/V 缓存	没有保留可复核的独立基准数字	不纳入最终配置，且不作收益结论。
激进 Inductor 融合	暖缓存、n_iter=2 局部运行186.60 s; 默认123.77 s	局部测试慢50.8%。
FP16 权重预转换	同一局部运行174.96 s; 默认123.77 s	生成 kernel 数减少，但整体延迟反而增加。
Channels-last-3D	同一局部运行125.34 s; 默认123.77 s	数值有效，但慢1.27%。
DDIM CUDA Graph	配对局部测试: 129.11 s 变为135.09 s, PSNR 均为 39.3627 dB	慢4.63%，且 capture 约需4.21 s；实验代码已撤回。

这些实验说明：降低 DDIM 步数首先受质量阈值限制；提高局部计算精度不一定使结果更接近 参考视频；kernel 数量减少也不等于端到端延迟下降。最终配置只保留在完整推理路径中验证 有效，并且20个样例全部通过 PSNR 的优化。

证据: `profiles/ddim_step_sweep_g1_case1_fp16/a40_v40`
证据: `profiles/stage3_batch_vae_output.log`
证据: `profiles/stage3_batch_vae_psnr.json`
证据: `baselines/2026-07-12_z1_dual_arm_stackbox_case1_unoptimized/output.log`
证据: `profiles/fp16_precision_ablation/RESULTS.md`
证据: `profiles/inductor_fusion_layout/report.md`
证据: `profiles/ddim_cuda_graph_g1_case1/stage4a_fixed_eager_equivalence`
证据: `profiles/ddim_cuda_graph_g1_case1/stage4d_cuda_graph_metadata_fixed`
证据: `profiles/tf32_z1_output.log`
证据: `profiles/tf32_z1_psnr.json`
证据: `profiles/bf16_z1_output.log`
证据: `profiles/bf16_z1_psnr.json`
证据: `profiles/fp16_z1_output.log`
证据: `profiles/fp16_z1_psnr.json`

参考资料

[1] ASC 组委会，《ASC26 预赛官方通知》，第3题，PDF 第4-10页，本地文件 `/home/cyc/ASC26_Preliminary_Round_Notification.pdf`。